

# plan

## RQ

**How do key chemical attribute affect wine quality, and do these relationships differ between red and white wines in ways that are relevant to winemaking decisions?**

这个版本最符合：- project instruction - 统计建模要求 (interactions, linear modeling theory)  
- 教授的三个主要批评 (lack of context、too broad、motivation unclear)

## 阶段 0: EDA

- 检查各变量分布，识别 skewness 并决定是否需要 transformation。
- 检查变量间的相关结构，识别 potential multicollinearity。
- 比较 red 与 white 的化学特征分布差异，识别 potential interaction。
- 根据 scatterplots 判断线性关系的方向与强弱。

此阶段不进行推断，不删除变量或观测点。

## 阶段 1: 构建 Candidate Models

- 根据 EDA 决定必要的 transformations (如 log-transform)。
- 删除无意义或高度共线的变量 (如 density)。
- 依据科学动机与 EDA 结果决定主要交互项：strong、moderate、weak。
- 构建满足 marginality 的 hierarchical models。

本阶段只定义候选模型，不做检验或推断。

## 阶段 2: 拟合模型

拟合多个 candidate models 以便后续比较，例如：

```
mA <- lm(...)  
mB <- lm(...)  
mC <- lm(...)  
mD <- lm(...)
```

## 阶段 3: 模型选择 (Model Selection)

允许使用：- AIC、BIC - Nested model F-tests (ANOVA) - Adjusted  $R^2$  - 科学解释性与可解释性

不允许使用：- stepwise regression - 使用 AIC/BIC 选择模型后再做未修正的 classical inference

原则：- AIC/BIC 仅用于在 candidate models 间选择。- 若差异显著，选择 AIC/BIC 较小的模型；若差异不显著，选择更简单、解释性更强的模型。- 最终模型确定后才能做 p-values、t-tests、CI 等推断。

## 阶段 4：模型诊断（Model Diagnostics）

检查四类假设：

### 1. Linearity

工具：Residuals vs Fitted

如出现曲线趋势，考虑 transformation 或添加交互项。

### 2. Constant variance (Homoscedasticity)

工具：Residuals vs Fitted

若异方差明显，可进行 predictor transform 或在结论中说明限制。

### 3. Normality of Errors

工具：QQ plot

大样本下，轻微非正态不影响估计量的近似正态性（由 CLT 保证）。

### 4. Influential Points

工具：Cook's Distance、Residuals vs Leverage

非数据录入错误的观测不可删除；仅在显著影响模型时记录其影响。

本阶段不修改数据，除非发现确凿的数据错误。

## 阶段 5：是否需要 L1 / L2 回归（可选）

- L1 (LASSO) 与 L2 (Ridge) 不能用于最终推断模型。
- 可作为 sensitivity analysis 检查系数稳定性。
- 在存在 multicollinearity 或系数不稳定时可使用。
- 典型适用情形：free\_sulfur\_dioxide 与 total\_sulfur\_dioxide、residual\_sugar 与 density。

结果仅作为补充，不进入最终推断框架。

## 阶段 6：最终模型推断（Inference）

在最终模型确定且 diagnostics 通过后：

- 检查 main effects 的方向、大小、显著性。
- 解释 interaction effects，阐述红白葡萄酒之间的差异。
- 绘制 interaction plots 说明斜率差异。
- 将统计结果与酿酒背景（chemistry/winemaking decisions）联系。

此阶段给出最终回答，即回答 research question。

## 阶段 7：写结论（Conclusion）

包含内容：

- 最终模型的主要科学发现 (main effects + interactions)。
- red 与 white wine 之间的系统性差异。
- 哪些化学属性最重要、如何影响 quality。
- 交互项揭示的 winemaking insights。
- 模型局限性: heteroscedasticity、non-normal tails、limited  $R^2$ 、未观测变量等。